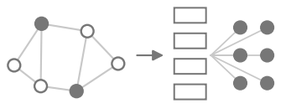
F01

从分离条件优化到训练实验选择

同一模型基础，两类决策目标

已有研究 分离条件优化

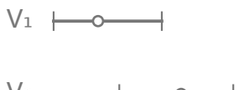
1



已训练的QGeoGNN

输入分子结构与候选条件

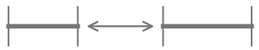
2



预测 V_1 / V_2 分布

用预测区间描述洗脱体积

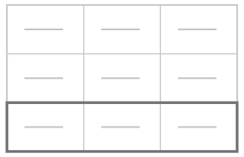
3



计算分离指标 S_p

评估候选条件下的分离表现

4



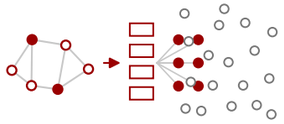
选择更好的分离条件

面向当前混合物推荐实验条件

目标 **优化分离结果**

本研究 训练数据采集优化

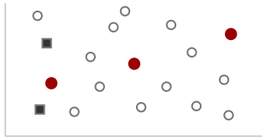
1



当前模型 + 候选实验池

综合预测与候选覆盖信息

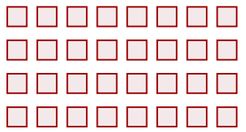
2



估计样本的学习价值

评估哪些实验值得补充标签

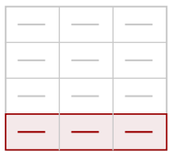
3



选择下一批训练实验

固定每轮32个唯一实验

4



获取新标签并更新模型

扩充已标记集，进入下一轮

目标 **提升模型数据效率**

图形均为方法示意：区间、点集与空白表格不代表实测结果；两条路径相互独立。

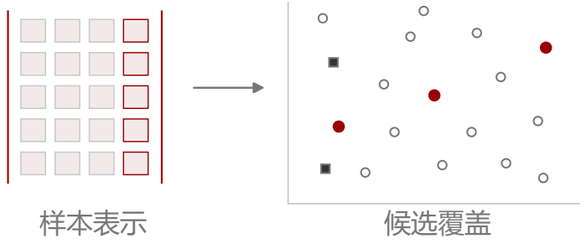
F02 科学问题与研究路线

研究总目标

面向柱色谱的数据高效学习

RQ1 数值选样

怎样衡量实验价值?

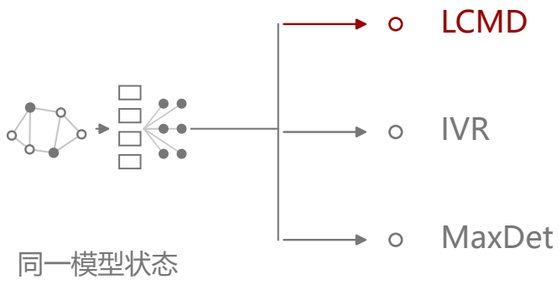


表征 × 选样准则

LCMD / IVR / MaxDet

RQ2 状态依赖策略

采样收益是否依赖模型状态?

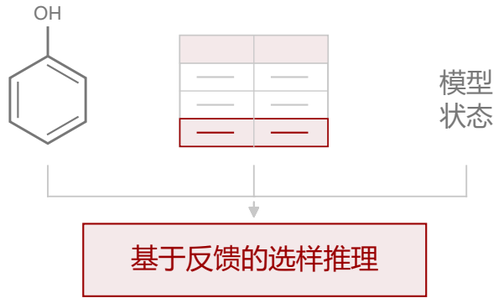


同状态分支实验

固定起点，分别追加标签

RQ3 反馈引导的LLM

化学知识与反馈
能否提供额外信息?



三种LLM机制

CW+LLM / 自由LLM / 双专家

统一评价　NRMSE · AULC · 达到目标所需标签数

图内的点集、特征槽与表格为概念示意；三个问题并列，在相同标签预算下评价。

F03 数值策略与LLM辅助的主动学习闭环

当前已实现：基于历史数据的离线主动学习模拟

未标记候选池 U_t · 分子结构与实验条件

真实自动化柱色谱平台
未来在线验证

01 **已标记数据集**

结构	V_1	V_2

L_t：结构、条件与实测标签

02 **QGeoGNN训练**

用当前已标记集训练

03 **预测与样本表示**

V_1

V_2

V_1/V_2预测 + 表征

04 **选样与批次选择**

B_t · 32个实验

05 **实验反馈**

ID	V_1	V_2

从历史记录揭示
所选实验的真实标签

06 **更新数据集**

结构	V_1	V_2

$L_{t+1} = L_t \cup B_t$

选样机制

冻结32个唯一实验后，再揭示标签

A 数值选样

梯度表示
LCMD / IVR / MaxDet

B LLM辅助选样

化学信息 / 已观察反馈
模型状态 / 科学推理

数值与LLM的组合方式及配额随方案而异

更新标签 → 重新训练 → 下一轮选样

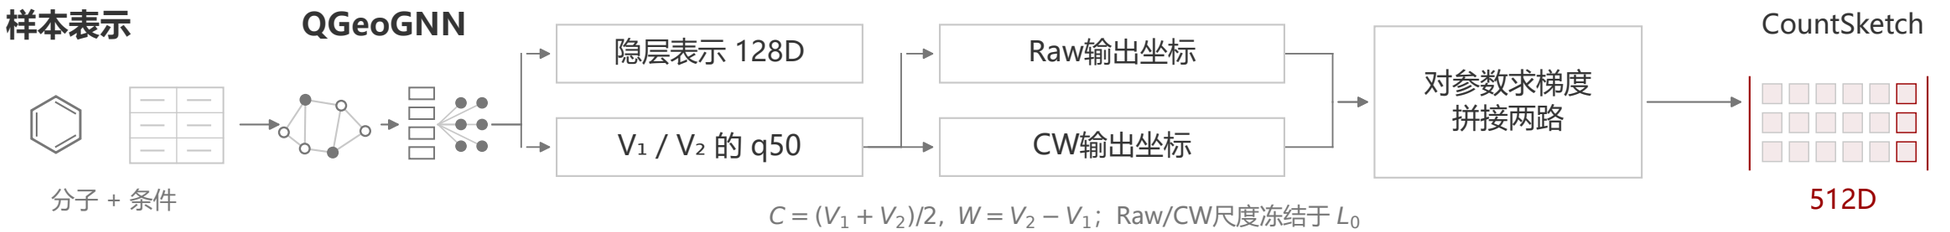
—— 已实现：离线模拟

----- 计划：在线验证

图内区间、特征槽和空白表格均为概念示意；候选与待测批次不含真实标签。

F04 数值主动学习：特征构造与采样准则的实际计算

二维构造算例直接运行原始选样函数；展开批次内的逐点选择、状态更新与重新评分



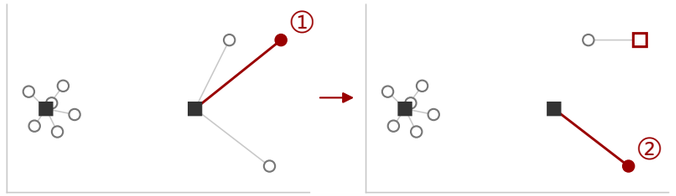
本轮特征固定
逐点更新选样状态
实验批次 B=32

$C = (V_1 + V_2)/2$，$W = V_2 - V_1$；Raw/CW尺度冻结于 L_0

a LCMD

按总平方距离选簇，再取簇内最远点

第一次选择　　加入①后重新分配



6点簇：0.260　　①成为新中心，改变候选归属

3点簇：2.045 → 先选①　　重算簇分数 → 再选②

■ 当前中心　○ 候选　红色：选中 / 新增

$$d_u = \min_{c \in \mathcal{C}} \|\phi_u - \phi_c\|^2$$

$$j^* = \arg\max_j \sum_{u:c(u)=j} d_u$$

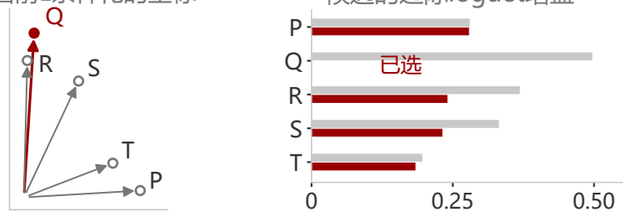
选中点加入中心集，更新最近距离与归属

初始 $\mathcal{C} = L_t$；不额外做RMS或逐行归一化

b MaxDet

在当前已标记集条件下，贪心增加logdet

经当前L条件化的坐标　　候选的边际logdet增益



首选Q → 重新评分 → 次选P

初始次高为R；加入Q后，P成为剩余最优

灰：首选前　红：加入Q后

$$A = I + X_L^T X_L + X_S^T X_S$$

$$\Delta_i = \log(1 + x_i^T A^{-1} x_i)$$

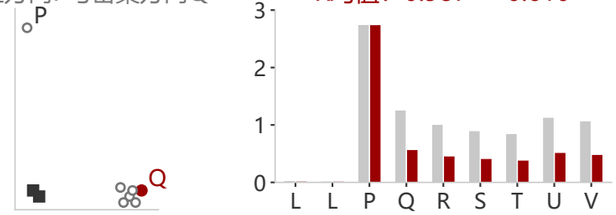
每选1个点，秩一更新并重算剩余增益

$x_i = \phi_i / s_L$；整体RMS尺度 s_L 仅由当前 L_t 计算

c IVR

选择使全参考集平均代理方差下降最多的点

孤立方向P与密集方向Q　　R均值：0.987 → 0.610



局部方差：P 2.733 > Q 1.244

IVR得分：P 0.224 < Q 0.377 → 先选Q

均匀参考；更新C后次选P | 灰：选前，红：选Q后

$$\mathrm{IVR}(i) = \frac{x_i^T C M C x_i}{1 + x_i^T C x_i}$$

$$C = (I + X_L^T X_L + X_S^T X_S)^{-1}$$

$$M = X_R^T X_R / N, \quad R = L_t \cup U_t$$

整体RMS来自R；单位先验 / 噪声；逐点更新C

算例为二维构造特征，非真实实验数据或降维结果；点位是显式构造输入，分数与选序由未修改的原始函数计算。

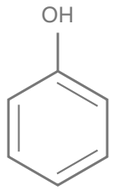
实验使用512D梯度特征并逐点选满32个；IVR是固定特征线性核的代理方差缩减，不是QGeoGNN的精确后验。

F05

化学知识与实验反馈驱动的LLM选样

信息边界：真实 V_1/V_2 仅来自已标记实验；未标记候选只能提供特征与预测

输入证据



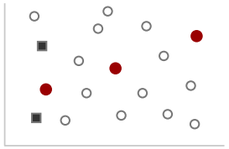
A 化学信息

分子结构 / 官能团
实验条件与洗脱体系

实测	预测

B 历史实验反馈

已观察的实测 V_1/V_2
预测残差与对应实验条件



C 当前模型状态

候选预测 / 不确定性代理
已标记与候选样本覆盖

基于证据形成选样假设

LLM辅助实验推理

已观察证据

1. 归纳实验反馈
2. 提出可检验假设
3. 给出选样理由

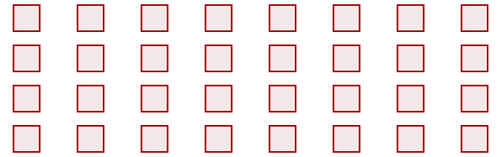
假设随新反馈修订

输出实验建议

选择建议与理由

唯一候选ID	选样依据

冻结批次



下一批32个实验

观察 → 假设 → 建议实验 → 新反馈

分子、点集与空白表格为概念示意；“假设”须经后续实验检验，不表示已发现化学规律。

F06

三种LLM选样机制：相同的32标签预算

共同输入：当前模型状态 + 候选实验池 + 已观察反馈

A CW16 + LLM16

CW-LCMD先选16个

先从LLM可选池排除CW16

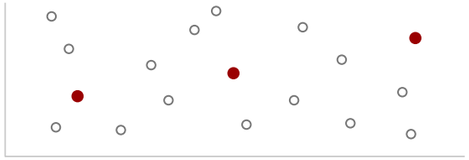
LLM补充另外16个

待测CW16仅提供预测，无真实标签

灰：CW16　红：LLM16

B 自由LLM32

完整候选池



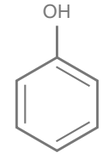
LLM自主选择32个

无CW预留配额

LLM选择32个

C 双专家LLM

化学科学家



机器学习科学家



独立建议　　独立建议

科学规划者汇总并最终选样

不预设两位专家的最终入选配额

规划者确定32个唯一实验

每批32个唯一合法ID；先冻结选择再揭示标签。双专家信息独立，代码按顺序调用。点集为示意。

F07 主动学习评价协议与标签预算

横轴只计训练标签；初始333个，每轮增加32个，固定验证集标签另计



AULC只在相同标签区间内比较

$$\mathrm{AULC}_{a:b} = \frac{1}{b-a}\sum_{i}(n_{i+1}-n_i)\frac{e_i+e_{i+1}}{2}$$

选样 → 揭示标签 → 重新训练 → 评价

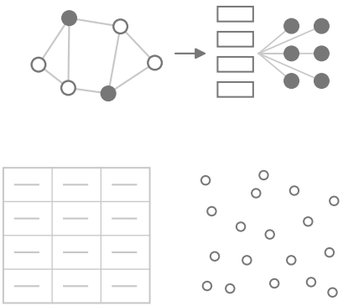
预算点使用真实线性坐标；813与1005分别对应15轮与21轮新增实验。

F08

同状态分支：策略收益是否依赖模型状态?

8个起始状态 = 2个seed × 2条历史轨迹 × 2个锚点（429 / 653）

同一模型检查点



已标记池 L_t　　候选池 U_t

LCMD

2轮 × 32 = +64标签

IVR

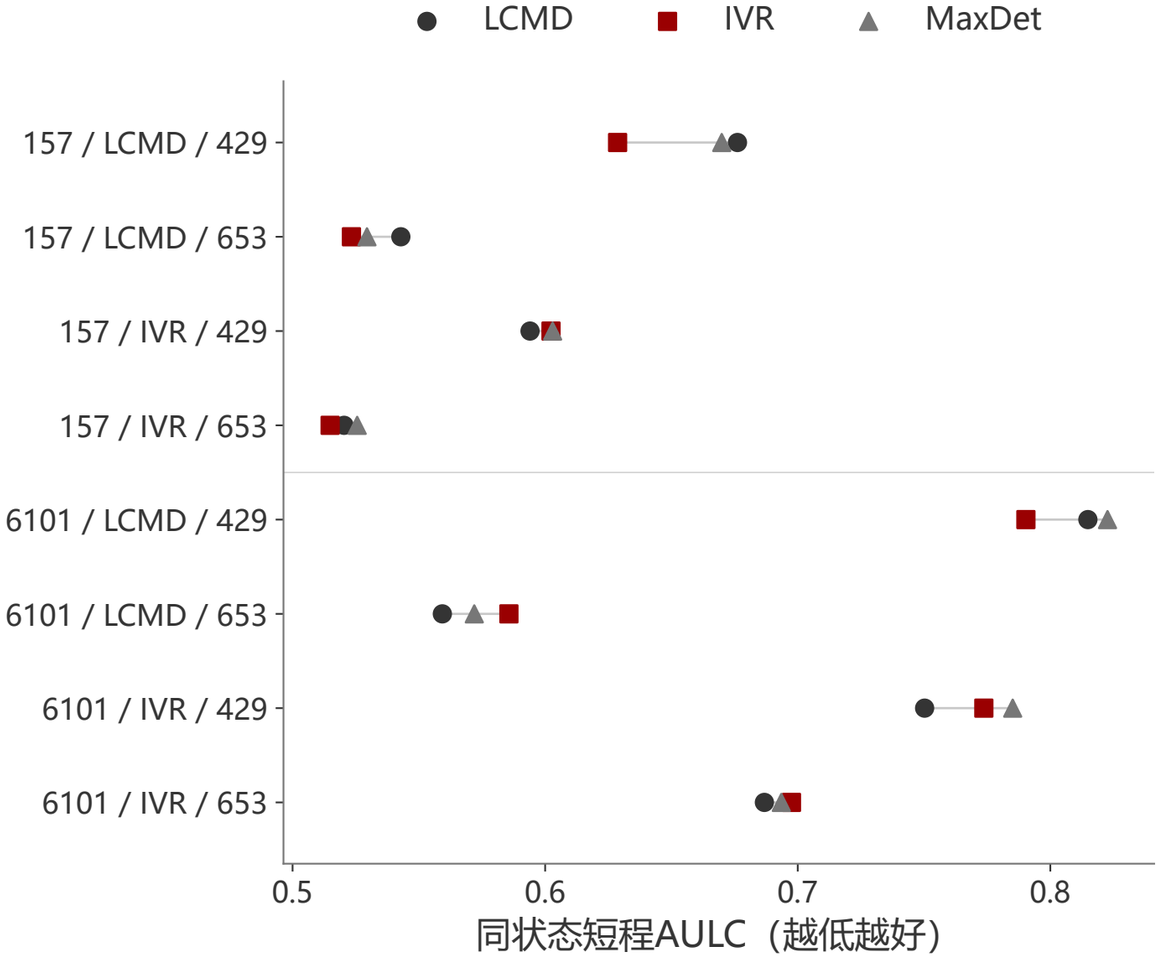
2轮 × 32 = +64标签

MaxDet

2轮 × 32 = +64标签

各起始状态内部比较
相同的新增标签预算

真实历史日志：各状态内配对比较



胜出次数：LCMD 4 / IVR 4 / MaxDet 0

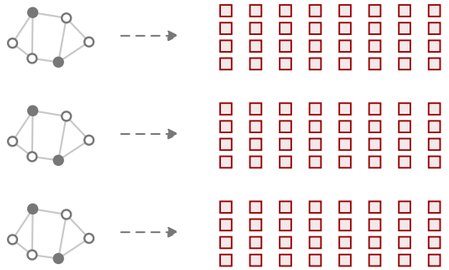
右图为全部分支冻结后揭示的历史test指标，仅作机制探索；不与验证集曲线直接排名。

F09

后续研究路线：稳健性、机制与真实验证

以下均为研究计划，尚未作为完整确认实验完成

I 稳健性



增加随机种子
加强数值策略基线

II 信息机制

	化学	反馈	对应
完整信息	✓	✓	✓
移除反馈	✓	✗	✗
移除化学	✗	✓	✓
打乱对应	✓	✓	✗

检验各类信息的增量贡献

III 泛化与真实验证



新分子 / 新条件　　固定评价协议

真实平台上的在线闭环

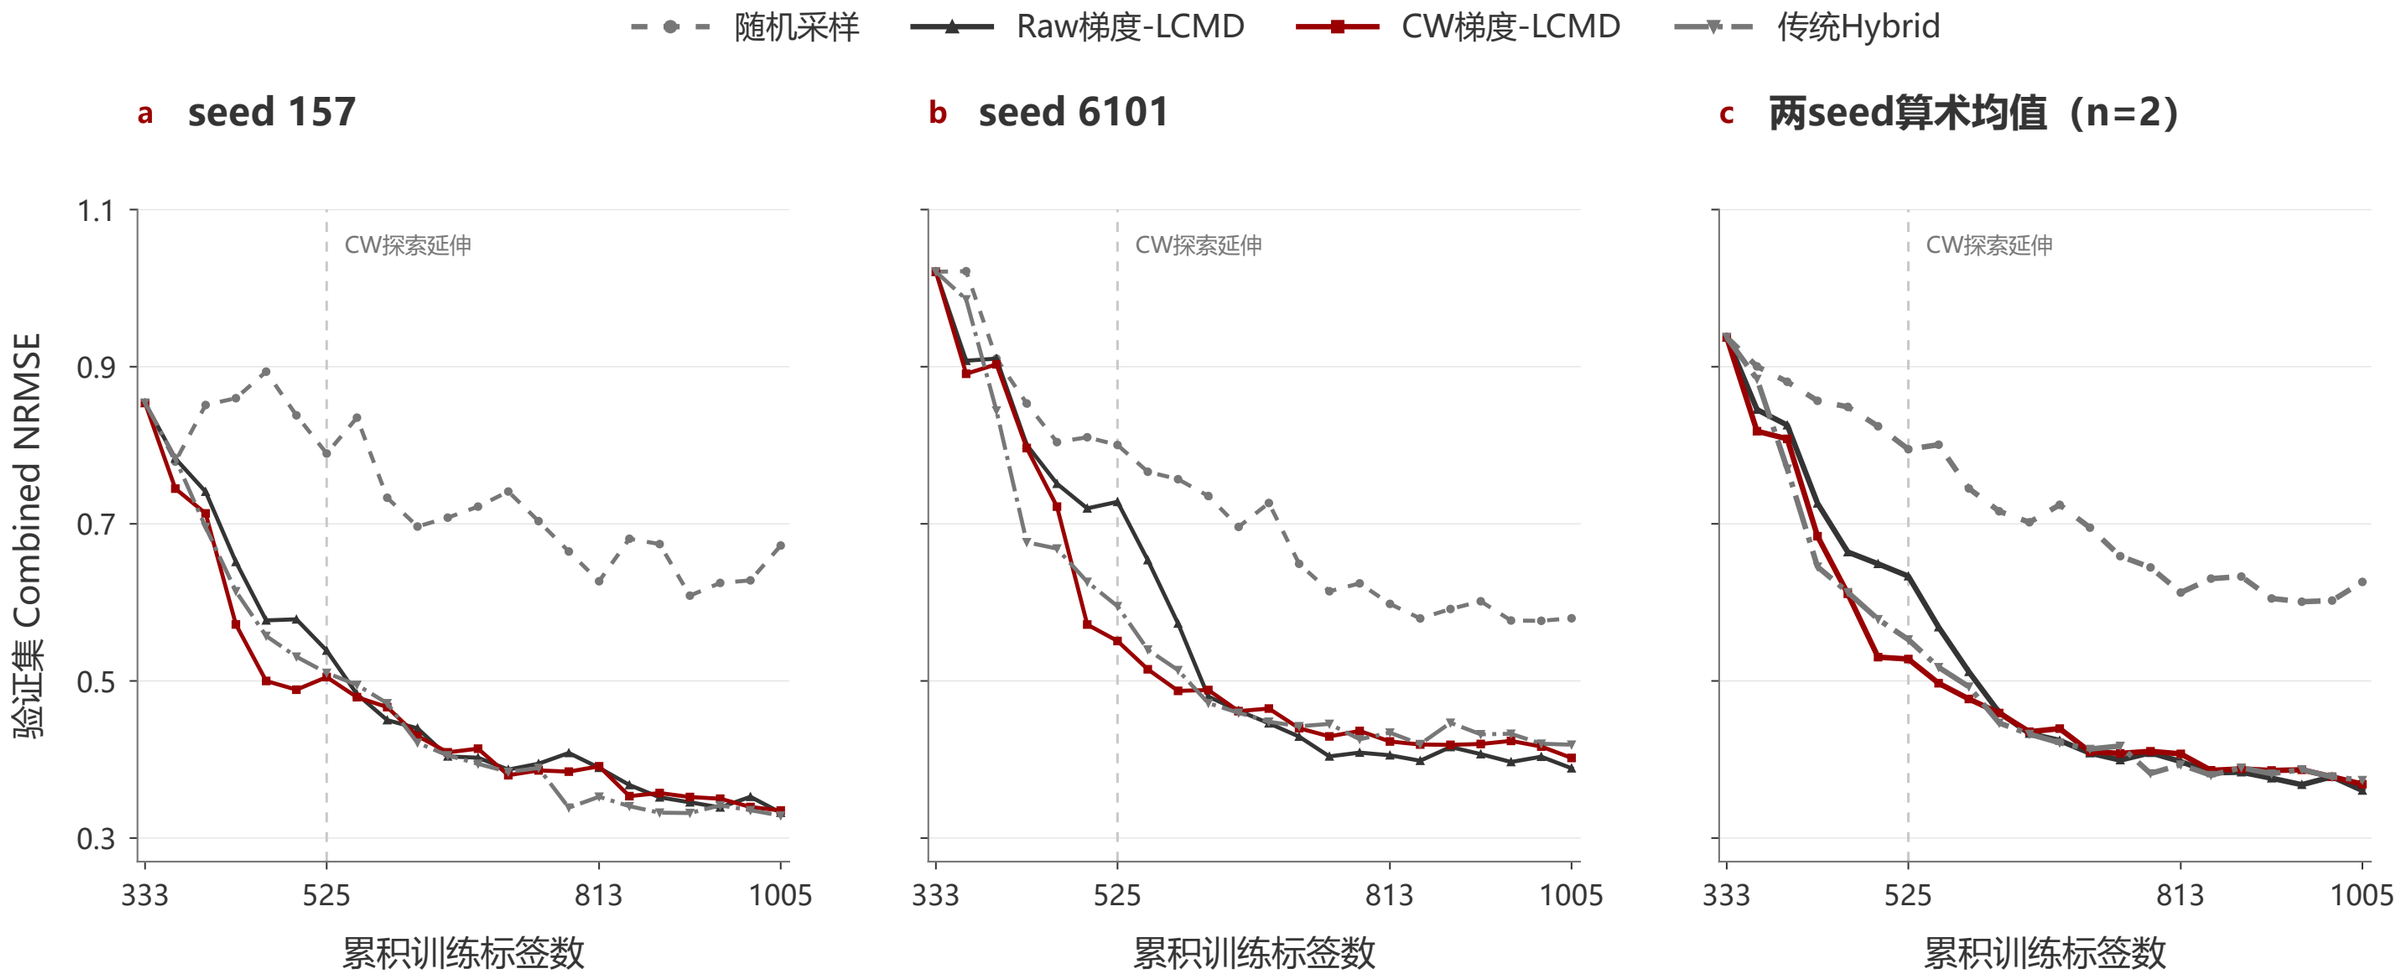
可靠的性能收益　　**可识别的信息价值**　　**实际应用能力**

稳健复现 → 机制解释 → 外部验证

虚线表示计划；中间表格表示拟保留或移除的信息，不是消融结果；预期贡献须由实验检验。

R01 数值主动学习策略：相同标签预算下的学习曲线

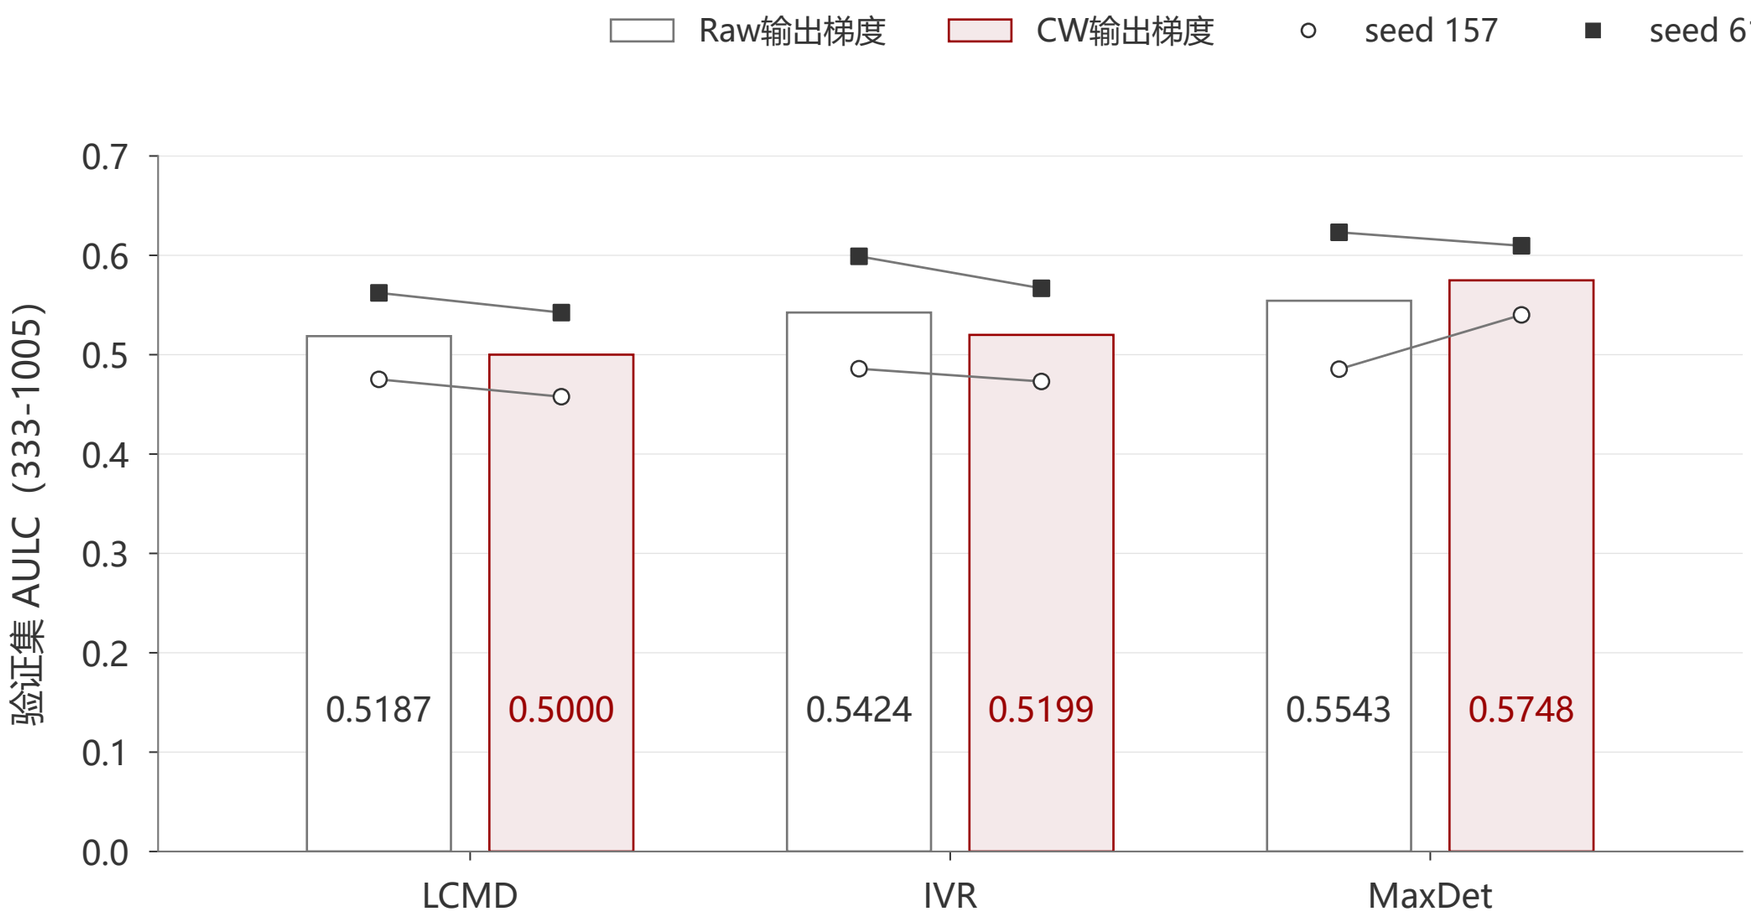
Row划分 · 验证集416条 · seed 157 / 6101 · 每轮32标签 · 333-1005标签 · NRMSE越低越好



左、中：真实单seed曲线；右：同预算两seed算术均值。标记为真实记录点，连接线仅便于阅读。
传统Hybrid使用K=3 ensemble，计算量更大；相同标签预算不等于相同计算预算。CW的525后阶段为探索性延伸。

R02 Raw与CW输出梯度：收益取决于具体选样准则

验证集AULC | 相同区间333-1005 | 两seed：157 / 6101 | 越低越好



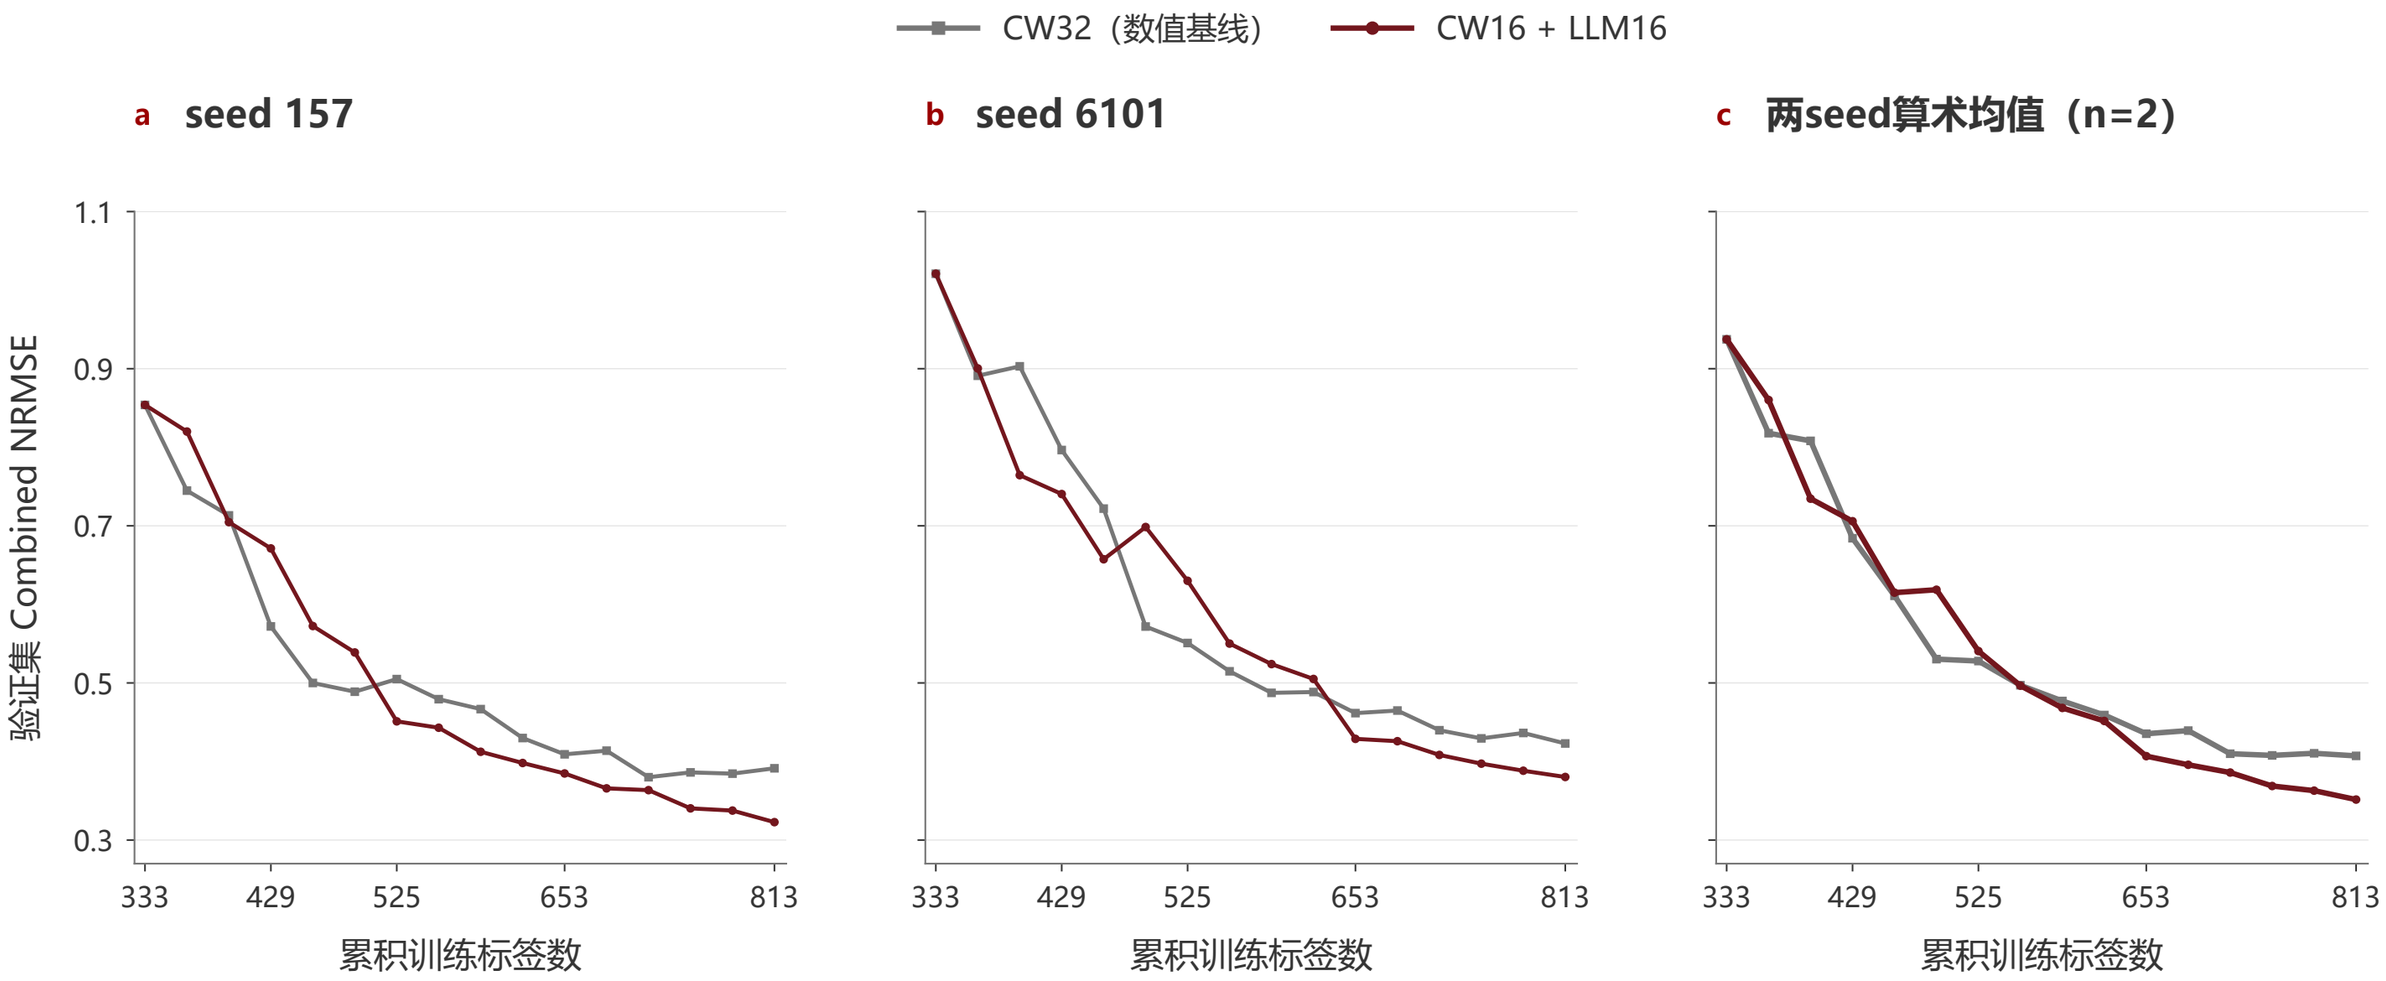
CW相对Raw的AULC变化

LCMD	-3.6%
两seed方向一致	
IVR	-4.2%
两seed方向一致	
MaxDet	+3.7%
两seed方向不一致	

柱高：两seed算术均值；圆点/方点：单seed原值；连线：同seed的Raw-CW配对。
不同选样准则还采用不同RMS尺度，跨准则差异不能完全归因于目标函数。525后为探索性延伸。

R03 CW32与CW16+LLM16：两seed学习曲线

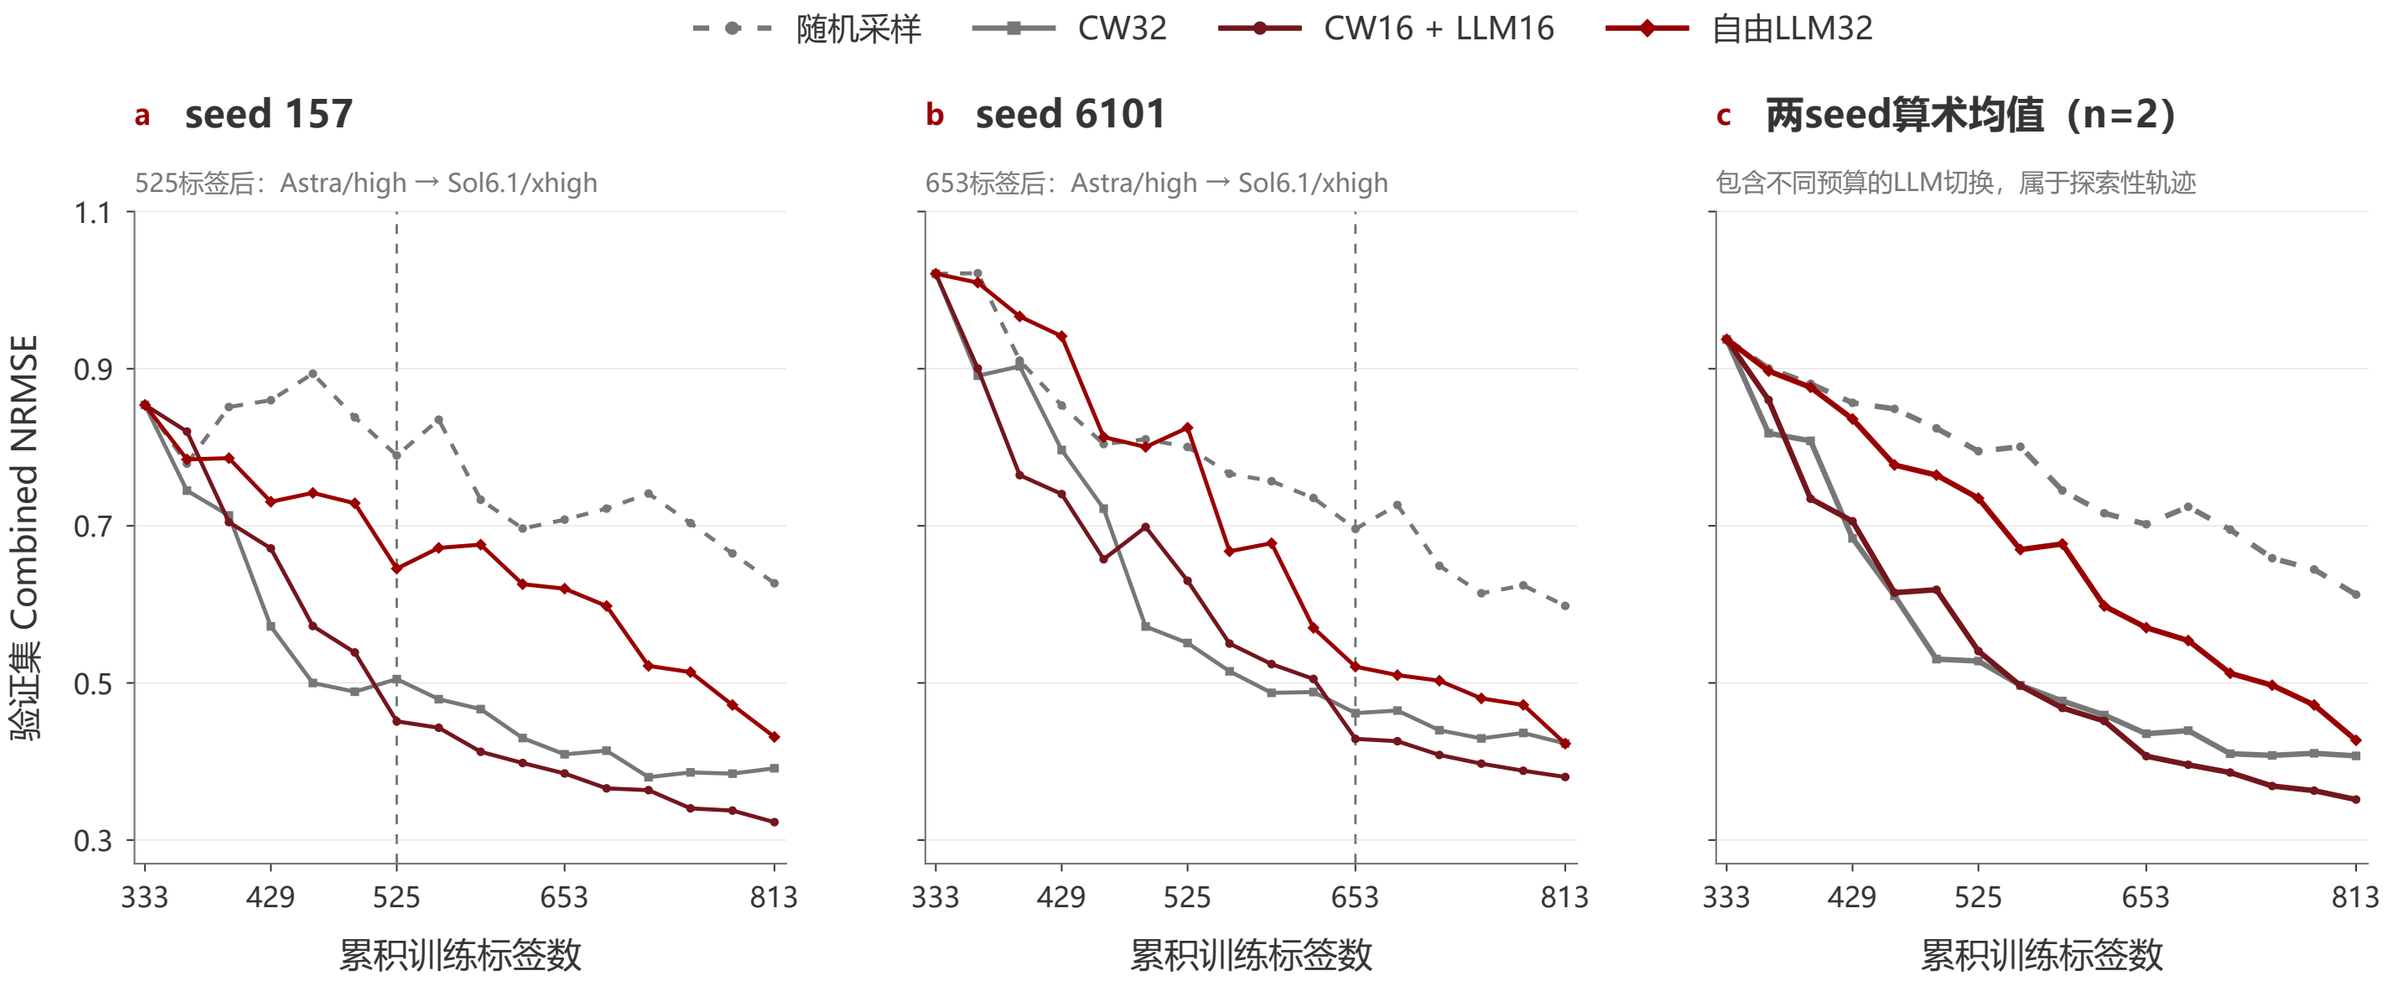
Row划分 · 验证集416条 · seed 157 / 6101 · 每轮32标签 · 333-813标签 · NRMSE越低越好



左、中：真实单seed曲线；右：同预算两seed算术均值。标记为真实记录点，连接线仅便于阅读。
LLM使用Astra/high；读取2026-10-11冻结快照的完整333-813轨迹。两seed开发性验证，不使用置信带。

R04 自由LLM32与相关对照：探索性学习曲线

Row划分 · 验证集416条 · seed 157 / 6101 · 每轮32标签 · 333-813标签 · NRMSE越低越好



左、中：真实单seed曲线；右：同预算两seed算术均值。标记为真实记录点，连接线仅便于阅读。
虚线标记Free LLM的模型切换预算；QGeoGNN训练协议相同。Astra前缀与Sol后续不能作为纯Sol实验解释。